Transformación de NHANES a OMOP Common Data Model

1. Objetivo y alcance

Transformar un subconjunto del dataset **NHANES (National Health and Nutrition Examination Survey), ciclo 2021-2023 ("_L")**, al modelo de datos común **OMOP CDM v5.4**, con foco en variables relevantes para el estudio de la diabetes: demografía, diagnóstico de diabetes/prediabetes y comorbilidades autoinformadas, analitos de laboratorio centrales (glucosa, HbA1c, insulina, HDL), y factores de riesgo conductuales (tabaquismo, alcohol, actividad física, antecedentes familiares, salud general autopercibida).

No se ha intentado una cobertura exhaustiva de las ~800 variables de laboratorio ni de las ~500 variables de cuestionario disponibles en NHANES: se ha priorizado un núcleo curado y verificado frente a una cobertura amplia sin verificar. Esta decisión se documenta y justifica en la sección 3.

2. Origen de los datos

Fuente: registro de Zenodo "NHANES Diabetes Data" (record 20032095), ciclo NHANES agosto 2021 - agosto 2023.
Estructura del dataset:
5 CSV de diccionario de variables: `demographics_variables.csv`, `dietary_variables.csv`, `examination_variables.csv`, `laboratory_variables.csv`, `questionnaire_variables.csv`.
~60 archivos `.xpt` (formato SAS Transport), uno por componente NHANES (`DEMO_L`, `BMX_L`, `GHB_L`, `GLU_L`, `DIQ_L`, `MCQ_L`, etc.), enlazables por `SEQN` (identificador único de participante).

2.1 Incidencia de calidad de datos detectada

Al inspeccionar los CSV de diccionario, se detectó que **`examination_variables.csv` y `questionnaire_variables.csv` están corruptos**: solo una parte inicial de cada uno corresponde de verdad a su componente declarado (92 de 511 filas son realmente `Examination`; 434 de 511 son realmente `Questionnaire`), y el resto es una cola idéntica copiada por error del final de `dietary_variables.csv`. `demographics_variables.csv` y `laboratory_variables.csv` se verificaron íntegros (100% de sus filas coinciden con su `Component` declarado).

Decisión: no usar `examination_variables.csv` ni `questionnaire_variables.csv` como inventario de qué variables existen; en su lugar, las columnas reales de las tablas cargadas en Postgres (ver sección 4) son la fuente de verdad.

3. Criterio de alcance

Dada la magnitud de NHANES (más de 60 tablas, cientos de variables por dominio, muchas irrelevantes para diabetes — paneles de compuestos orgánicos volátiles, hepatitis, hormonas, exposición ambiental...), se decidió:

Priorizar variables directamente relevantes al objetivo del ejercicio (diabetes y sus comorbilidades/factores de riesgo).
Verificar cada `concept_id` utilizado contra el vocabulario cargado localmente (tabla `vocabularies.concept`), en vez de asumir valores de memoria o de fuentes externas sin comprobar.
Se probó un enfoque de automatización mediante *fuzzy matching* de texto (TF-IDF) entre descripciones de variables NHANES y nombres de conceptos LOINC, con el objetivo de ampliar la cobertura sin revisión manual variable a variable. **El resultado fue descartado**: falló en las 4 variables de laboratorio más centrales del ejercicio (glucosa emparejada con un test de orina, HDL con LDL, insulina con un test de anticuerpos, HbA1c con una entrada de ruido). La causa de fondo es que LOINC codifica analito + tipo de muestra + método en una sintaxis muy comprimida que el solape de texto no logra distinguir de forma fiable. Se mantuvo la verificación manual como único método fiable.

4. Infraestructura técnica

Base de datos: contenedor Docker `nhanes_db` (`postgres:latest`), con el volumen montado en `/var/lib/postgresql` (no en `/var/lib/postgresql/data`, requisito de Postgres 18+).
Esquemas:
`base`: tablas crudas cargadas desde los `.xpt` (una tabla por componente, nombres en minúscula: `demo_l`, `diq_l`, `mcq_l`, `glu_l`, `ghb_l`, `hdl_l`, `ins_l`, `smq_l`, `alq_l`, `paq_l`, `huq_l`...).
`vocabularies`: vocabularios estándar de OHDSI/Athena (ver sección 5).
`staging` / `cdm`: modelos dbt (ver sección 6).
Carga de los `.xpt`: script Python (`pandas.read_sas` + `sqlalchemy`) que crea una tabla por archivo `.xpt`, con nombres de columna en minúscula.
Proyecto dbt: reutiliza y adapta la plantilla del ejercicio previo (`diabetes_granada`), con `profiles.yml` dentro del propio proyecto (`profiles/profiles.yml`) y variables de conexión vía `.env` (`OMOP_BASE_SCHEMA=base`, `OMOP_VOCAB_SCHEMA=vocabularies`, etc.).

5. Vocabularios (Athena/OHDSI)

Bundle descargado de Athena con: **SNOMED, ICD9CM, LOINC, Gender, Race**, y posteriormente ampliado con **RxNorm y RxNorm Extension** para `DRUG_EXPOSURE`.

Cargados en el esquema `vocabularies` (tablas: `concept`, `vocabulary`, `domain`, `concept_class`, `concept_relationship`, `relationship`, `concept_synonym`, `concept_ancestor`, `source_to_concept_map`, `drug_strength`) vía un script de `\copy` tabla por tabla.

Nota sobre RxNorm: la tabla `drug_strength` y los conceptos de `RxNorm`/`RxNorm Extension` requieren una licencia UMLS (gratuita) vinculada a la cuenta de Athena; sin ella, Athena filtra ese contenido del bundle descargado aunque se haya marcado en la selección. Trámite en curso al cierre de este documento.

6. Convenciones del proyecto dbt

Casts explícitos con `::TIPO` (no `cast(x as tipo)`).
Toda la lógica de transformación vive en `models/staging/`; los modelos de `models/cdm/` son passthroughs simples (`select * from {{ ref('stg_...') }}`).

`person_id`: se usa la clave natural (`seqn`) directamente allí donde ya es un identificador único (caso NHANES), sin generar un surrogate `ROW_NUMBER()` salvo que la clave de origen no sea un entero limpio.
Fechas imputadas: NHANES no proporciona fechas reales (solo edad y ciclo de encuesta). Se usa de forma consistente el rango real del ciclo `_L` (**2021-08-01 a 2023-08-31**) para `observation_period`, y el primer día del ciclo (**2021-08-01**) como fecha de referencia en `condition_occurrence`, `measurement` y `observation`. `year_of_birth` se aproxima como **2022** (año intermedio del ciclo) menos la edad en el momento de la encuesta.
Verificación de `concept_id`: todo concepto usado en los modelos se verificó contra `vocabularies.concept` del propio proyecto (por nombre exacto o por `concept_code`), nunca asumido de memoria sin comprobar.

7. Tablas OMOP implementadas

7.1 PERSON

Fuente: `base.demo_l`.

Campo OMOP	Origen / lógica
`person_id`	`seqn`
`year_of_birth`	`2022 - ridageyr` (aproximado, ver sección 6)
`gender_concept_id`	`riagendr`: 1→8507 (Male), 2→8532 (Female)
`race_concept_id`	`ridreth1`: 3→8527 (White), 4→8516 (Black or African American), 5→8522 (Other Race), resto→8552 (Unknown, incluye códigos hispanos)
`ethnicity_concept_id`	`ridreth1` in (1,2)→38003563 (Hispanic or Latino); in (3,4,5)→38003564 (Not Hispanic or Latino)

Se separa raza de etnia siguiendo el criterio de no traducir los códigos hispanos de `RIDRETH1` a una raza específica, evitando conflar ambos conceptos.

7.2 OBSERVATION_PERIOD

Fuente: `base.demo_l`.

`observation_period_start_date` = `2021-08-01`, `observation_period_end_date` = `2023-08-31` (rango completo del ciclo, imputado para todos los participantes).
`period_type_concept_id` = **44814723** ("Period while enrolled in study").

7.3 CONDITION_OCCURRENCE

Dos fuentes combinadas (`UNION ALL`):

a) Diabetes/Prediabetes — `base.diq_l`, variable `DIQ010`:

1 (Sí) → `condition_concept_id` = **201820** (Diabetes mellitus)
3 (Borderline) → `condition_concept_id` = **37018196** (Prediabetes)

b) 12 condiciones autoinformadas — `base.mcq_l`, vía seed de mapeo + despivote (patrón: unpivot de columnas anchas a formato largo `person_id, variable_name, value`, unión contra un seed `variable_name → concept_id`, filtrando `value = 1`):

Variable	Condición	`concept_id`
MCQ010	Asma	317009
MCQ160a	Artritis	4291025
MCQ160b	Insuficiencia cardíaca congestiva	4023479
MCQ160c	Cardiopatía coronaria	317576
MCQ160d	Angina	321318
MCQ160e	Infarto de miocardio	312327
MCQ160f	Ictus	381316
MCQ160l / MCQ500	Enfermedad hepática	194984
MCQ160m	Trastorno de tiroides	141253
MCQ160p	EPOC	255573
MCQ220	Cáncer	443392
MCQ550	Cálculos biliares	196456

`condition_type_concept_id` = **45905770** ("Patient Self-Reported Condition") para ambas fuentes.

Verificado: no hay duplicados de "enfermedad hepática" por persona pese a que `MCQ160l` y `MCQ500` son variables alternativas de la misma pregunta según patrón de salto (cada participante solo responde una de las dos).

7.4 MEASUREMENT

Núcleo curado de 4 analitos centrales:

Variable	Analito	`measurement_concept_id` (LOINC)	`unit_concept_id`
LBXGLU	Glucosa en ayunas	3037110 (1558-6)	8840 (mg/dL)
LBXGH	HbA1c	3004410 (4548-4)	8554 (%)
LBDHDD	Colesterol HDL	3007070 (2085-9)	8840 (mg/dL)
LBXIN	Insulina	3016244 (20448-7)	9093 (µIU/mL)

Fuentes: `base.glu_l`, `base.ghb_l`, `base.hdl_l`, `base.ins_l`. `measurement_type_concept_id` = **44818702** ("Lab result" — mediciones reales del examen físico/laboratorio, no autoinformadas).

7.5 OBSERVATION

Dos fuentes combinadas:

a) 4 variables binarias (mismo patrón de seed + despivote que en `CONDITION_OCCURRENCE`, solo se genera fila cuando la respuesta es "Sí"):

Variable	Dominio	`observation_concept_id`
SMQ020	Tabaquismo (¿ha fumado ≥100 cigarrillos en su vida?)	648645
ALQ111	Alcohol (¿alguna vez ha bebido alcohol?)	3027199
PAQ650	Actividad física vigorosa	4266975
MCQ300C	Antecedentes familiares de diabetes	4051114

b) Salud general autopercibida — `base.huq_l`, variable `HUQ010`: escala ordinal 1-5, tratada aparte del patrón binario. El código ordinal se guarda directamente en `value_as_number` (simplificación deliberada, sin mapear cada nivel de la escala a un `concept_id` de respuesta individual), con `observation_concept_id` = **4247398** ("Health status").

`observation_type_concept_id` = **45905771** ("Observation Recorded from a Survey") para todas las fuentes.

7.6 DRUG_EXPOSURE

Pendiente. Bloqueado por la carga de RxNorm/RxNorm Extension, que requiere licencia UMLS vinculada a la cuenta de Athena (trámite en curso). Fuente prevista: `RXQ_RX_L` (medicación autoinformada).

8. Resumen de tablas OMOP completadas

Tabla	Estado
PERSON	✅ Completa
OBSERVATION_PERIOD	✅ Completa
CONDITION_OCCURRENCE	✅ Completa (diabetes/prediabetes + 12 condiciones)
MEASUREMENT	✅ Completa (4 analitos core)
OBSERVATION	✅ Completa (4 binarias + salud general)
DRUG_EXPOSURE	⏳ Pendiente (bloqueado por licencia UMLS)